

# Case Prático: Detecção de Atividades Suspeitas de Lavagem de Dinheiro

Nós da CloudWalk buscamos alternativas inovadoras para detectar atividades suspeitas de lavagem de dinheiro e financiamento ao terrorismo. Isso inclui a implementação de soluções tecnológicas avançadas que possam identificar padrões anômalos e classificar transações com base no risco.

A CloudWalk considera diversas técnicas e estratégias para garantir uma detecção eficaz e abrangente. Você, como analista de prevenção à lavagem de dinheiro e financiamento ao terrorismo, deve definir estratégias para implementar essas soluções de maneira eficiente, considerando o uso de diferentes tecnologias, incluindo Large Language Models e outras técnicas de Machine Learning.

Estamos animados para avaliar suas habilidades e sua capacidade de propor soluções práticas para um cenário próximo ao real de compliance e prevenção à lavagem de dinheiro. Abaixo estão as etapas do case e orientações sobre o que esperamos que você demonstre em cada uma delas.

## Tarefas do Case

O time de Monitoramento de Prevenção à Lavagem de Dinheiro realizou um mutirão para avaliar a base de dados de determinado período. Considerando que você faz parte do time e utilizando seus conhecimentos e estudos da questão anterior, utilize a base de dados enviada e responda às seguintes tarefas:

### 1. Análise com Dados Transacionais Simulados

**Tarefa:** Trabalhe com a amostra de dados transacionais fornecida, que inclui campos como ID do cliente, valor da transação, horário, localização, tipo de pagamento e histórico de transações. Explore esses dados para realizar análises que você consideraria relevantes na identificação de padrões suspeitos de lavagem de dinheiro. De acordo com a sua análise, há algum estabelecimento que tenha apresentado algum indício de suspeita lavagem de dinheiro, financiamento ao terrorismo ou algum possível ato ilícito?

**Objetivo:** Buscamos entender como você interpreta dados e quais métodos e insights você aplicaria para simular um cenário prático de compliance.

### **Resolução:**

Considerando que o perfil dos clientes na amostra é semelhante, a média das quantias nas transações é de aproximadamente \$ 3.106,87, enquanto o desvio padrão é de \$ 4.823,95. Dessa forma, foi estabelecido que transações superiores a \$ 9.647,90 (duas vezes o valor do desvio padrão) devem ser consideradas suspeitas. Tais transações exigem a aplicação de uma flag para que sejam submetidas a diligências adicionais e monitoramento, com o objetivo de identificar e mitigar riscos elevados, transformando-os em riscos mais baixos.

No primeiro trimestre de 2021, 70,1% das transações, consideradas normais, totalizaram:

- Janeiro: \$ 341 mil
- Fevereiro: \$ 306 mil
- Março: \$ 311 mil

Já as transações suspeitas, que representam 29,9%, somaram:

- Janeiro: \$ 66 mil
- Fevereiro: \$ 19,4 milhões
- Março: \$ 8,7 milhões

Nessa análise, as transações suspeitas estão concentradas no método de pagamento em crédito, com maior frequência em pagamentos com cartões físicos.

---

## **2. Interpretação e Explicabilidade do Modelo de Machine Learning**

**Tarefa:** Em um ambiente de compliance, é essencial que as previsões sejam interpretáveis. Como você garantiria que o modelo de machine learning seja explicável para a equipe de compliance, especialmente em casos complexos de lavagem de dinheiro? Dica: Inclua técnicas de interpretação de modelos, como SHAP ou LIME, e comente como essas técnicas podem auxiliar a equipe a entender as razões por trás da classificação de uma transação como suspeita.

**Objetivo:** Avaliar sua capacidade de comunicar decisões do modelo de maneira transparente e explicável, o que ajuda na defesa das decisões e na confiança da equipe.

**Resolução:** Machine Learning é uma técnica que permite que computadores aprendam com dados, sem serem explicitamente programados para cada tarefa. Em um cenário de combate à lavagem de dinheiro, podemos utilizar ML para analisar **grandes volumes de**

**transações financeiras e identificar padrões** que poderiam ser indicativos de atividades suspeitas como:

- Transações incomuns;
- Transferências entre contas não relacionadas;
- Quantias altas em momentos específicos.

Uma ferramenta que pode ser utilizada para explicar um modelo é a **LIME (Local Interpretable Model-agnostic Explanations)**. Ela melhora a eficiência, a transparência e o controle nas investigações, além de otimizar a precisão do modelo com o tempo.

### **Como o LIME pode ser útil em casos de lavagem de dinheiro?**

O modelo de ML pode indicar que uma transação é suspeita, mas a equipe precisa saber quais características geram essa conclusão. LIME analisa essas características, como:

- O valor da transação;
- O histórico de transações da conta;
- Padrões de horários;
- Relacionamento entre contas (por exemplo, contas de mesmo titular ou de países de alto risco.)

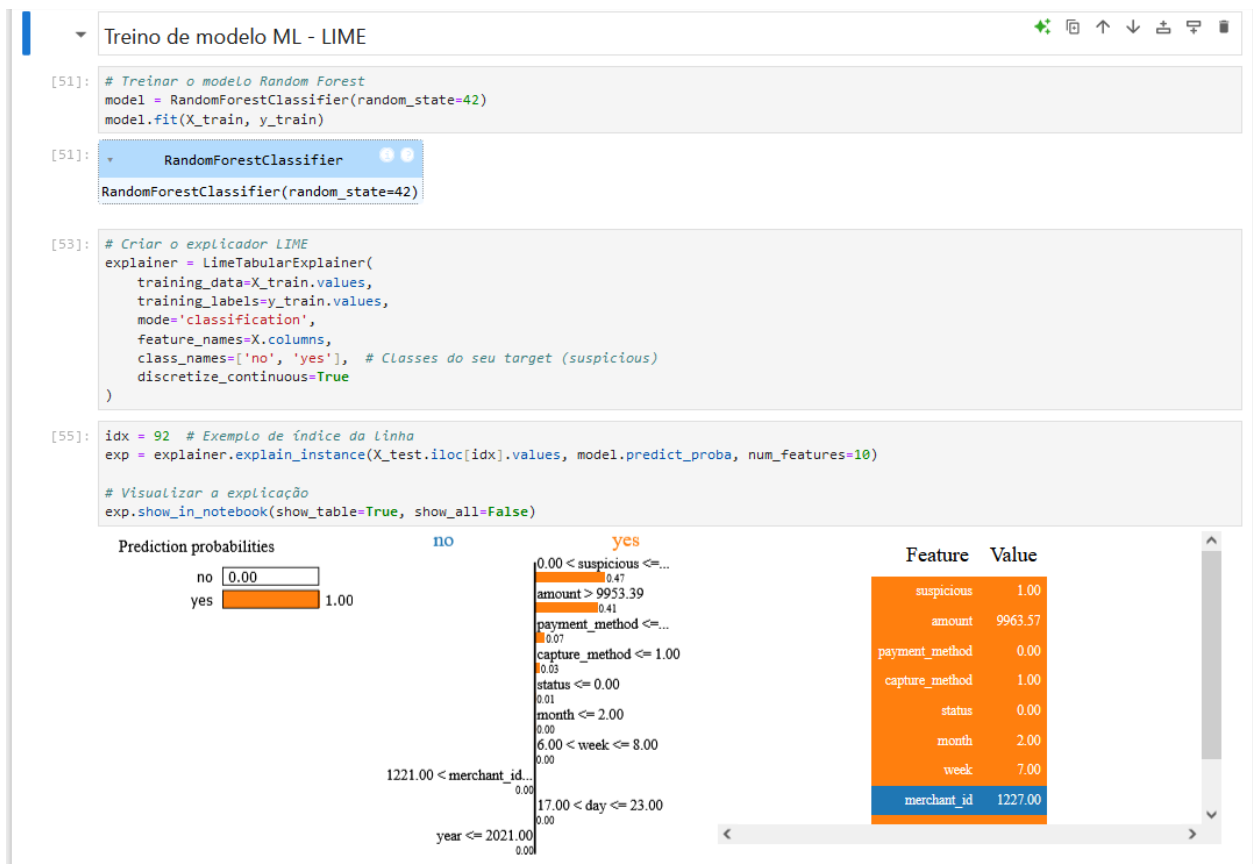
Nisso, a ferramenta complementa com as características das transações:

- Valor acima do normal;
- Variação de destino de pagamento;
- Taxa de transações altas em curto período de tempo.

Em uma amostra de transação como suspeita, as variáveis “amount” e “payment\_method” têm pesos substanciais para a análise de predição.

- O **valor da transação** foi um dos fatores mais importantes. O modelo considera que, transações com valor acima de \$ 9953.39 são mais propensas a serem suspeitas, contribuindo com 47% para a decisão.
- O **método de pagamento** também tem grande peso, com 42% de contribuição. Isso pode indicar que certos métodos de pagamento são mais frequentemente associados a transações suspeitas.

Em suma, o modelo de machine learning pode ajudar a detectar padrões de lavagem de dinheiro automaticamente e o LIME ajuda a explicar o porquê da identificação suspeita, facilitando a interpretação da equipe de compliance.



Observação: para melhor manuseio, o link do script, em repositório, está em anexo no email.

### 3. Escolha de Métricas de Avaliação para Classificação de Risco

**Tarefa:** Quais métricas de avaliação você usaria para medir o desempenho do modelo de classificação de risco? Justifique o uso de cada métrica, considerando a necessidade de minimizar tanto os falsos positivos quanto os falsos negativos.

**Objetivo:** Queremos entender sua visão sobre as métricas de avaliação e sua justificativa para o uso de cada uma, especialmente na busca por um equilíbrio ideal entre precisão e recall, crucial para o sucesso em compliance.

**Resolução:**

**Entendimento do Contexto**

- O modelo está classificando transações como **suspeitas de fraude** (classe positiva) ou **não suspeitas** (classe negativa).

- No contexto de **fraude**, minimizamos
  - **falsos positivos** (classificar erroneamente uma transação legítima como fraude) e;
  - **falsos negativos** (não identificar uma fraude real).

### Métricas de Avaliação Relevantes

Com base nesse contexto, as métricas mais relevantes são:

(Legenda)

- **TP** (Verdadeiro Positivo): Fraudes corretamente identificadas.
- **TN** (Verdadeiro Negativo): Transações não fraudulentas corretamente identificadas.
- **FP** (Falso Positivo): Transações não fraudulentas incorretamente identificadas como fraude.
- **FN** (Falso Negativo): Fraudes não identificadas corretamente.

### Precisão

- **Definição:** A precisão mede a proporção de **transações classificadas como fraudulentas que realmente são fraudulentas**.

**Fórmula:**  $\text{Precisão} = \text{TP} / (\text{TP} + \text{FP})$

**Justificativa:** A precisão é importante quando o custo de falsos positivos é alto. No caso de fraude, um falso positivo (transação legítima marcada como fraude) pode levar a ações desnecessárias e desconforto para o cliente. Um modelo com alta precisão reduz esse risco.

### Recall (Sensibilidade ou Taxa de Verdadeiros Positivos)

- **Definição:** O recall mede a proporção de transações fraudulentas que foram corretamente identificadas pelo modelo.
- **Fórmula:**  $\text{Recall} = \text{TP} / (\text{TP} + \text{FN})$
- **Justificativa:** O recall é crucial quando o custo de falsos negativos é alto. No caso de fraude, um falso negativo (fraude não detectada) pode resultar em grandes perdas financeiras ou danos à reputação da instituição. Ter um modelo com alto recall é essencial para garantir que a maioria das fraudes seja identificada.

### F1-Score

- **Definição:** O F1-score é a média harmônica entre a precisão e o recall. Ele combina as duas métricas em um único número, equilibrando tanto os falsos positivos quanto os falsos negativos.
- **Fórmula:**  $\text{F1} = 2 \times (\text{Precisão} \times \text{Recall} / (\text{Precisão} + \text{Recall}))$
- **Justificativa:** O F1-score é útil quando há necessidade de um equilíbrio entre precisão e recall, como no caso de fraudes, onde tanto os falsos positivos quanto os falsos negativos precisam ser minimizados. Ele oferece uma métrica única que reflete o desempenho geral do modelo.

```
[135]: dataset.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9391 entries, 0 to 9390
Data columns (total 16 columns):
#   Column                Non-Null Count  Dtype
---  -
0   transaction_id         9391 non-null   object
1   merchant_id            9391 non-null   object
2   transaction_date        9391 non-null   datetime64[ns]
3   transaction_time        9391 non-null   object
4   status                 9391 non-null   object
5   amount                 9391 non-null   float64
6   payment_method          9391 non-null   object
7   capture_method          9391 non-null   object
8   card_holder_name        9391 non-null   int32
9   card_number            9391 non-null   object
10  year                   9391 non-null   int32
11  month                  9391 non-null   int32
12  week                   9391 non-null   UInt32
13  day                    9391 non-null   int32
14  suspicious             9391 non-null   object
15  status_code            9391 non-null   int64
dtypes: UInt32(1), datetime64[ns](1), float64(1), int32(4), int64(1), object(8)
memory usage: 999.8+ KB

[137]: dataset['suspicious'] = dataset['suspicious'].astype('int32')

[139]: y_true = dataset['suspicious']
       y_pred = dataset['status_code']

[141]: precision = precision_score(y_true, y_pred)
       recall = recall_score(y_true, y_pred)
       f1 = f1_score(y_true, y_pred)

[151]: # Exibindo os resultados
       print(f'Precision: {precision}')
       print(f'Recall: {recall}')
       print(f'F1-Score: {f1}')

Precision: 0.6514611546685674
Recall: 0.32584670231729057
F1-Score: 0.4344106463878327
```

## 4. Simulação de Relatório de Atividades Suspeitas (SAR)

**Tarefa:** Usando o LLM (Language Model), crie um relatório SAR para uma transação fictícia suspeita. Estructure o relatório de forma que seja claro para reguladores e intuitivo para o time de compliance, detalhando o contexto e os motivos da suspeita.

**Objetivo:** Avaliar sua habilidade de criar relatórios de atividades suspeitas que sejam informativos e bem-estruturados. Este exercício mostra como você aplicaria um LLM na criação de relatórios de compliance.

**Resolução:**

### Relatório de Atividade Suspeita (SAR)

**Data do Relatório:** 08 de dezembro de 2024

**Nome do Analista:** George Feitosa

**Departamento:** Compliance

**Informações Gerais da Transação**

- **ID da Transação:** 125143
- **Data e Hora da Transação:** 16 de fevereiro de 2021, às 14:19
- **Valor da Transação:** \$ 9.998,24
- **Método de Pagamento:** Pagamento com cartão de Crédito
- **Contas Envolvidas:**
  - **Número de Cartão:** 509063\*\*\*\*\*2012

**2. Descrição da Transação Suspeita**

A transação em questão foi uma compra no crédito de \$ 9.998,24 realizada de uma conta de origem em nome de um indivíduo que, com base na análise preliminar, não parece ter uma relação clara com o valor ou a natureza da transação.

**3. Motivo da Suspeita**

A transação foi identificada como suspeita devido aos seguintes fatores:

- **Valor elevado:** A transferência de \$ 9.998,24 é significativamente superior ao histórico de transações do cliente, que normalmente realiza transações no valor médio de \$ 244,58.
- **Padrão de comportamento incomum:** O cliente realizou um único pagamento, de valor expressivamente mais alto, para uma conta de destino que não consta como beneficiária recorrente nas transações anteriores.
- **Origem da conta:** A conta de origem foi aberta há menos de dois meses, e o cliente tem pouco histórico de movimentação financeira.
- **Conta de Destino:** A conta de destino pertence a uma pessoa física, mas o endereço e as informações cadastrais associadas à conta de destino não correspondem a um padrão de clientes típicos da plataforma.
- **Suspensão de Comunicação:** O cliente não respondeu aos nossos esforços de contato para esclarecimento da transação.

**4. Análise Contextual e Circunstancial**

O comportamento da transação foge ao padrão do cliente e da plataforma. A conta de origem foi aberta de forma recente, sem histórico substancial de transações, e a movimentação financeira realizada foi de um valor elevado e em um único pagamento para um destinatário desconhecido. Esse tipo de transação é frequentemente associado a tentativas de lavagem de dinheiro ou financiamento de atividades ilícitas, sendo, portanto, necessário que a transação seja investigada mais a fundo.

**5. Medidas Tomadas**

- **Congelamento da Transação:** A transação foi imediatamente interrompida e os fundos foram bloqueados enquanto aguardam uma investigação mais aprofundada.
- **Contatos com o Cliente:** Foram feitos esforços para entrar em contato com o cliente a fim de obter mais informações sobre a origem e a finalidade da transação. Até o momento, não houve resposta.
- **Análise de Risco:** A transação foi submetida à equipe de compliance para análise de risco detalhada.

## 6. Ações Recomendadas

- **Investigar a conta de destino:** Verificar se a conta de destino está associada a qualquer outra atividade suspeita ou criminosa.
- **Solicitar informações adicionais ao cliente:** Continuar tentando obter informações mais detalhadas sobre o motivo da transação e a relação do cliente com a conta de destino.
- **Relatar ao COAF (Conselho de Controle de Atividades Financeiras):** Submeter o caso à autoridade regulatória para investigação adicional sobre possíveis atividades de lavagem de dinheiro ou financiamento ao terrorismo.

## 7. Conclusão

Dado o alto valor da transação, o comportamento anômalo do cliente, e a falta de informações claras sobre o destino dos fundos, a transação será considerada suspeita até que se obtenham esclarecimentos. Recomendamos que a investigação continue e que a transação seja formalmente reportada ao COAF.

---

## 5. Proposta de Interface para Monitoramento e Acompanhamento de Alertas

**Tarefa:** Desenhe ou descreva uma interface básica onde a equipe de compliance possa ver alertas, acompanhar métricas como a taxa de falsos positivos e falsos negativos, e fornecer feedback sobre as previsões do modelo.

**Objetivo:** Com este exercício, queremos ver como você pensaria em uma interface colaborativa e prática que facilite o monitoramento e o ajuste contínuo do modelo de compliance.

**Resolução:**





Observação: o link do dashboard segue no corpo do email, assim como o arquivo em repositório.

## Questões do Case

### Estratégias de Minimização de Risco:

1. Quais práticas você implementaria para segmentar clientes de alto e baixo risco na etapa de onboarding?

Resolução:

**Análise de risco baseada em dados:** Implementar um modelo de avaliação de risco que considere fatores como localização geográfica no país, ocupação (ex:PEPs), histórico transacional, natureza do negócio (média de transações e quantias)

**Classificação Automatizada:** Usar algoritmos de *machine learning* para atribuir automaticamente escores de risco com base em critérios objetivos.

**2. Como você trataria casos de clientes com histórico de problemas de conformidade ao serem aceitos novamente?**

**Resolução:**

**Revisão Estrita:** Realizar uma análise detalhada do histórico de conformidade, identificando se o problema foi isolado, intencional ou sistemático.

**Termos Condicionados:** Aceitar o cliente apenas com condições rigorosas, como monitoramento contínuo de transações, limites operacionais e auditorias periódicas.

**Experiência do Usuário:** 3. Como você equilibraria as exigências de conformidade com uma boa experiência de usuário?

**Resolução:**

**Comunicação Transparente:** Informar os clientes de forma clara sobre o motivo de cada etapa do processo e oferecer suporte em tempo real para resolver dúvidas.

**Personalização:** Adaptar o nível de rigor conforme o perfil do cliente, evitando exigir informações excessivas de clientes de baixo risco.

**Validação de Identidade:** 4. Quais métodos de validação biométrica considera mais eficazes e por quê?

**Resolução:**

**Reconhecimento Facial com Liveness Check:** Combina alta segurança e conveniência, dificultando fraudes com fotos ou vídeos.

**Impressões Digitais:** Confiável em ambientes que exigem autenticação física.

Porque ambos os métodos têm alta eficácia e ampla adoção por reguladores e experiência de usuário positiva.

**Automação e Eficiência Operacional:** 5. Quais partes do processo de KYC você acredita que são mais impactantes para automatizar, e quais manteria manuais?

**Resolução:**

Em automatizações:

- Verificação de identidade (documentos e biometria).
- Busca em bases de dados globais (sanções, PEPs, listas negativas).
- Classificação de risco com base em algoritmos.

Em procedimentos manuais, apenas que carecem de julgamento humano.

- Análise de casos atípicos e investigações aprofundadas.
- Decisões finais em clientes de alto risco, que requerem julgamento humano.

**Análise de Dados e Monitoramento Contínuo:** 6. Que tipo de dados adicionais você acredita que deveriam ser monitorados durante o relacionamento contínuo com o cliente?

**Resolução:**

- Mudanças em perfis transacionais: Monitorar desvios significativos no padrão esperado do cliente.
- Atualização de dados cadastrais: Identificar alterações em ocupação, endereço ou status como PEP.
- Eventos externos: Integrar dados de fontes públicas, como notícias sobre envolvimento do cliente em atividades suspeitas.

**Tecnologia e Inovação:** 7. Como você usaria dados de fontes externas, como redes sociais e processos judiciais, para enriquecer o perfil de risco do cliente?

**Resolução:**

- Análise de Sentimentos e Reputação: Usar algoritmos de processamento de linguagem natural (NLP) para identificar sinais de risco em postagens públicas.
- Integração com Registros Judiciais: Automatizar consultas a processos judiciais para identificar possíveis envolvimentos em fraudes ou crimes financeiros.
- Privacidade e Consentimento: Garantir conformidade com leis de privacidade, como LGPD, obtendo consentimento explícito para usar esses dados.

**Desafios e Problemas Práticos:** 8. Quais problemas operacionais considera mais críticos no processo de onboarding e como os resolveria?

**Resolução:**

- Demora na Verificação de Identidade: Resolver com validação automatizada em tempo real.

- Falsificação de Documentos: Mitigar com tecnologias avançadas de detecção de fraudes em documentos.
- Processo Fracionado: Centralizar o fluxo em uma plataforma única para reduzir erros e aumentar a eficiência.

## **O que iremos avaliar?**

Avaliaremos como você aplicaria IA e Machine Learning para análise de comportamento e transações, considerando métricas, desafios e limitações, além de como mitigaria esses pontos. Também levaremos em conta seu equilíbrio entre conformidade e experiência do usuário, destacando pontos de atrito e soluções. Esperamos entender sua abordagem em validação biométrica e tratamento de falsos positivos, assim como a automação eficiente de processos de KYC, mantendo a segurança nas revisões.

Serão observadas suas sugestões de dados adicionais para monitoramento contínuo e configuração de alertas para clientes de risco moderado. Consideraremos ainda o impacto de atualizações regulatórias no onboarding, a gestão de conformidade entre jurisdições, o uso de dados externos para enriquecer perfis de risco e novos avanços tecnológicos aplicados à AML. Por fim, veremos como lida com desafios operacionais no onboarding e assegura a qualidade dos dados em verificações de AML.

Estamos ansiosos para ver sua abordagem analítica e criativa em cada uma dessas etapas. As respostas a cada item nos ajudarão a entender como você aplica seus conhecimentos na prática e propõe soluções colaborativas para o time de compliance.

**Boa sorte!**